

# Probabilidad y estadística

## Unidad 7: Procesos estocásticos - Cadenas de Markov

Katherine Sullivan

FCEIA - UNR

# Índice

## 1 Introducción

- Otros procesos estocásticos y su abordaje
- Cadenas de Markov (CM): definición y ejemplos

## 2 Probabilidades en cadenas de Markov

- ¿Cómo hablar de probabilidades en una CM?
- ¿Qué probabilidad tengo de llegar a un estado  $x$ ?
- Clasificación de estados
- Alcanzabilidad en exactamente  $n$  pasos
- Distribución estacionaria de una cadena de Markov

## 3 Repaso

- ¿Qué podemos hacer con cadenas de Markov?

## ¿Qué es una cadena de Markov?

- Una cadena  $\rightarrow$  un proceso estocástico con espacio de estados,  $S$ , discreto (a veces -y en este caso-, conjunto de instantes de observación,  $T$ , discreto)
- de Markov  $\rightarrow$  cuyas variables aleatorias cumplen la propiedad markoviana

$\forall i_0, i_1, \dots, i_{n-1}, i, j$  se cumple

$$P(X_{n+1} = j / X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = i) = P(X_{n+1} = j / X_n = i)$$

futuro                      pasado                      presente

## Diferentes enfoques

Podríamos estudiar las CM viéndolas como:

- una familia de variables aleatorias, o
- un sistema de transición con estados y transiciones probabilistas entre estados

Usaremos este último

## ¿Por qué pensar un enfoque con estados?

Pensar las cadenas de Markov con un enfoque con estados y transiciones resulta

- más *computacional*, y
- es como se las suele estudiar en el campo de la verificación de modelos

# Cadena de Markov

## Definición

Una cadena de Markov es una tupla  $\mathcal{M} = (S, \mathbf{T}, \iota_{init})$  donde

- $S$  es un conjunto de estados numerable y no vacío
- $\mathbf{T} : S \times S \rightarrow [0, 1]$  es la función de probabilidad de transición y es tal que para todo estado  $s \in S$


$$\sum_{s' \in S} \mathbf{T}(s, s') = 1$$

- $\iota_{init} : S \rightarrow [0, 1]$  es la distribución inicial y es tal que  $\sum_{s \in S} \iota_{init}(s) = 1$

## Algunos comentario sobre cómo estudiaremos a las CMs

- Es usual identificar la función de probabilidad de transición  $\mathbf{T} : S \times S \rightarrow [0, 1]$  con la matriz  $(\mathbf{T}(s, t))_{s, t \in S}$ . La fila  $\mathbf{T}(s, \cdot)$  para el estado  $s$  contiene las probabilidades de pasar del estado  $s$  a sus sucesores, mientras que la columna  $\mathbf{T}(\cdot, s)$  para el estado  $s$  especifica la probabilidad de entrar al estado  $s$  desde cualquier otro estado.
- Similarmente, se suele ver a la distribución inicial como el vector  $(\nu_{init}(s))_{s \in S}$ .
- Una cadena de Markov induce un grafo dirigido subyacente, donde los estados actúan como vértices y habrá una arista de  $s$  a  $s'$  sii  $\mathbf{T}(s, s') > 0$ , y generalmente son ilustradas de esta manera.
- Hablaremos de caminos en CMs. Un camino es una secuencia infinita de estados  $\pi = s_0 s_1 s_2 \cdots \in S^\omega$  tal que  $\mathbf{T}(s_i, s_{i+1}) > 0$  para todo  $i \geq 0$ . Notaremos al conjunto de caminos en una CM  $\mathcal{M}$  con  $Paths(\mathcal{M})$ .

## Ejemplos de cadenas de Markov - Protocolo simple de comunicación



$$\mathbf{T} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & \frac{1}{10} & \frac{9}{10} \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

$$\mathbf{l}_{init} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$



## ¿Cómo hablar de probabilidades en una CM?

- Queremos razonar sobre la probabilidad de ciertos conjuntos de caminos.
- Para ello necesitamos un marco matemático que nos permita asignar probabilidades a conjuntos (eventos) de manera rigurosa.
- Este marco será la teoría de la medida a través de *espacios de probabilidad* y  $\sigma$ -álgebras.
- Antes de poder asignarle probabilidades a este, un evento debe poder ser *probabilizable*.
- Un evento será *probabilizable* o, en la teoría de la medida, medible, solo si pertenece a un álgebra o  $\sigma$ -álgebra.

## Definición de $\sigma$ -álgebra

Sea  $\text{Outc}$  un conjunto no vacío de resultados y  $\mathcal{A} \subseteq 2^{\text{Outc}}$  un subconjunto de este cuyos elementos serán los que queremos medir (y a los que llamaremos eventos). El par  $(\text{Outc}, \mathcal{A})$  es una  $\sigma$ -álgebra si cumple:

- ①  $\emptyset \in \mathcal{A}$ .
- ② Si  $A \in \mathcal{A}$  entonces  $\bar{A} = \text{Outc} \setminus A \in \mathcal{A}$  (cierre por complemento).
- ③ Si  $A_1, A_2, \dots \in \mathcal{A}$  entonces  $\bigcup_{n \geq 1} A_n \in \mathcal{A}$  (cierre por uniones contables).

Y tendremos:

- $\text{Outc} \in \mathcal{A}$  como  $\text{Outc} = \bar{\emptyset}$ .
- Cierre también por intersecciones contables como  $\bigcap_{n \geq 0} A_n = \overline{\bigcup_{n \geq 0} \bar{A}_n}$

## Ejemplos de $\sigma$ -álgebras

- **Potencia completa:**  $\mathcal{A} = 2^{\text{Outc}}$  (todos los subconjuntos son eventos).
- **Trivial:**  $\mathcal{A} = \{\emptyset, \text{Outc}\}$  (solo el vacío y el universo como eventos).

# Espacio de probabilidad

Un **espacio de probabilidad** es una tripla  $(\text{Outc}, \mathcal{A}, \text{Pr})$  donde:

- $(\text{Outc}, \mathcal{A})$  es un  $\sigma$ -álgebra.
- $\text{Pr} : \mathcal{A} \rightarrow [0, 1]$  es una medida de probabilidad, es decir, es tal que:
  - 1  $\text{Pr}(\text{Outc}) = 1$ .
  - 2 Si  $A_i$  disjuntos dos a dos,  $\text{Pr}(\bigcup_i A_i) = \sum_i \text{Pr}(A_i)$ .

## Ejemplo: Moneda justa

- $\text{Outc} = \{\text{cara}, \text{cruz}\}$ ,  $\mathcal{A} = 2^{\text{Outc}}$ .
- Una medida de probabilidad podría ser:

$$\Pr(\{\text{cara}\}) = \Pr(\{\text{cruz}\}) = \frac{1}{2}, \Pr(\emptyset) = 0, \Pr(\text{Outc}) = 1.$$

## $\sigma$ -álgebra en cadenas de Markov

Para definir una  $\sigma$ -álgebra apropiada para una cadena de Markov, usaremos el hecho de que para cada conjunto  $\text{Outc}$  y cada subconjunto  $\Pi$  de  $2^{\text{Outc}}$  **existe una  $\sigma$ -álgebra más pequeña que contiene a  $\Pi$ .**

Esto es debido a las observaciones de que:

- el conjunto potencia  $2^{\text{Outc}}$  es una  $\sigma$ -álgebra, y
- la intersección de  $\sigma$ -álgebras es una  $\sigma$ -álgebra.

Consecuentemente, la intersección  $\mathcal{A}_\Pi = \bigcap_{\mathcal{A}} \mathcal{A}$  donde  $\mathcal{A}$  itera sobre todas las  $\sigma$ -álgebras en  $\text{Outc}$  que contienen a  $\Pi$  es una  $\sigma$ -álgebra y está contenida en cualquier  $\sigma$ -álgebra  $\mathcal{A}$  tal que  $\Pi \subseteq \mathcal{A}$ .  $\mathcal{A}_\Pi$  se llama la  **$\sigma$ -álgebra generada por  $\Pi$**  y  $\Pi$  es la base para  $\mathcal{A}_\Pi$ .

## $\sigma$ -álgebra en cadenas de Markov

- Para una cadena de Markov  $\mathcal{M}$ , los eventos serán los caminos infinitos:  $\text{Outc}^{\mathcal{M}} = \text{Paths}(\mathcal{M})$ .
- La  $\sigma$ -álgebra asociada con  $\mathcal{M}$  será la generada por los conjuntos cilindros asociados a los fragmentos de caminos finitos en  $\mathcal{M}$ .

### Definición (Conjunto cilindro)

El conjunto cilindro de  $\hat{\pi} = s_0 \dots s_n \in \text{Paths}_{fin}(\mathcal{M})$  se define como

$$\text{Cyl}(\hat{\pi}) = \{\pi \in \text{Paths}(\mathcal{M}) \mid \hat{\pi} \text{ es prefijo de } \pi\}.$$

Los conjuntos cilindros sirven entonces como los eventos base de la  $\sigma$ -álgebra  $\mathcal{A}^{\mathcal{M}}$  asociada a  $\mathcal{M}$ .

## Sigma álgebra de una cadena de Markov

### Definición

*La  $\sigma$ -álgebra  $\mathcal{A}^{\mathcal{M}}$  asociada a  $\mathcal{M}$  es la  $\sigma$ -álgebra más pequeña que contiene a todos los conjuntos cilindro  $\text{Cyl}(\hat{\pi})$  donde  $\hat{\pi}$  itera sobre todos los fragmentos de camino finitos en  $\mathcal{M}$ .*

Por resultados clásicos de teoría de probabilidad, existe una única medida  $\text{Pr}^{\mathcal{M}}$  en  $(\text{Paths}(\mathcal{M}), \mathcal{A}^{\mathcal{M}})$  tal que:

$$\text{Pr}^{\mathcal{M}}(\text{Cyl}(s_0 \dots s_n)) = \iota_{\text{init}}(s_0) \cdot \mathbf{T}(s_0 s_1 \dots s_n).$$

donde

$$\mathbf{T}(s_0 s_1 \dots s_n) = \prod_{0 \leq i < n} \mathbf{T}(s_i, s_{i+1})$$

y para fragmentos de longitud 0,  $\mathbf{T}(s_0) = 1$



## Notación LTL

Antes de seguir, haremos unas aclaraciones sobre la notación. Para describir ciertos conjuntos de caminos en una cadena de Markov usaremos notación LTL. Lo importante a saber de la notación LTL para comprender la presentación será:

- Al evento de alcanzar eventualmente, es decir, en una cantidad finita de pasos, algún estado de un conjunto de estados  $B$  lo notaremos  $\Diamond B$ .
- Al evento de solo pasar por estados en un conjunto  $C$  hasta eventualmente llegar a un estado de un conjunto  $B$  lo notaremos  $CU B$ .
- A ambas notaciones para eventos las podremos anotar con restricciones en esa cantidad de pasos finitos hasta llegar al conjunto de estados deseados. Por ejemplo:
  - $\Diamond^=n B$  notará el evento de alcanzar  $B$  en exactamente  $n$  pasos.
  - $CU^{\leq n} B$  notará el evento de alcanzar  $B$  antes solo habiendo pasado por estados en  $C$  en a lo sumo  $n$  pasos.

## Probabilidades de alcanzabilidad I

Una de las preguntas elementales para el análisis de sistemas es “¿cuál es la probabilidad de eventualmente llegar a cierto conjunto  $B$  de estados?”. Es decir, nos preguntamos por  $\Pr^{\mathcal{M}}(\Diamond B)$ , usando notación LTL. Pensemos en el ejemplo del protocolo simple de comunicación que vimos y pensemos que nuestro objetivo es computar cuál es la probabilidad de llegar al estado *delivered*.

Para este evento, los fragmentos de caminos iniciales  $s_0 \dots s_n$  con  $s_i \neq \textit{delivered}$  para  $0 \leq i < n$  y  $s_n = \textit{delivered}$  son de interés. Estos fragmentos de caminos tendrán la forma

$$\hat{\pi}_n = \textit{start try} (\textit{lost try})^n \textit{delivered}$$

donde  $n$  es un número natural arbitrario. La probabilidad de  $\hat{\pi}_n$  ocurra será  $(\frac{1}{10})^n \cdot \frac{9}{10}$ . Entonces,  $\Pr^{\mathcal{M}}(\Diamond \textit{delivered}) = \sum_{n=0}^{\infty} (\frac{1}{10})^n \cdot \frac{9}{10} = \frac{\frac{9}{10}}{1 - \frac{1}{10}} = 1$ .

## Probabilidades de alcanzabilidad II

El ejemplo anterior muestra cómo las probabilidades de llegar a cierto conjunto de estados pueden ser calculadas a través de sumas infinitas. Esto en ejemplos complejos puede ser muy difícil de calcular. Por eso, veremos cómo podemos computar esto de manera más eficiente.

Llamaremos  $x_s$  a la variable que denota la probabilidad de llegar a  $B$  desde  $s$ , para algún  $s$  arbitrario. I.e.,  $x_s = \Pr(s \models \Diamond B)$  en notación LTL.

Si  $B$  no es alcanzable desde  $s$  en el grafo subyacente,  $x_s = 0$ , mientras que si es alcanzable  $x_s > 0$  y si  $s \in B$ ,  $x_s = 1$ .

Para los estados  $s \in S \setminus B$  para los cuales  $B$  es alcanzable vale que:

$$x_s = \underbrace{\sum_{t \in S \setminus B} \mathbf{T}(s, t) \cdot x_t}_{\text{doy un paso y veo la probabilidad desde ahí}} + \underbrace{\sum_{u \in B} \mathbf{T}(s, u)}_{\text{llego en un paso}}$$

## Probabilidades de alcanzabilidad III

Denotemos ahora con  $\tilde{S}$  al conjunto de estados  $s \in S \setminus B$  que alcanzan  $B$ , i.e., para los que existe un fragmento de camino finito  $s_0 s_1 \dots s_n$  ( $n > 0$ ) con  $s_0 = s$  y  $s_n \in B$ .

Entonces para el vector  $\mathbf{x} = (x_s)_{s \in \tilde{S}}$  tenemos que

$$\mathbf{x} = \mathbf{Ax} + \mathbf{b},$$

donde

- la matriz  $\mathbf{A}$  contiene las probabilidades de transición para los estados en  $\tilde{S}$ , i.e.,  $\mathbf{A} = (\mathbf{T}(s, t))_{s, t \in \tilde{S}}$ , y
- el vector  $\mathbf{b} = (b_s)_{s \in \tilde{S}}$  contiene las probabilidades de alcanzar  $B$  en un paso, i.e.,  $b_s = \mathbf{T}(s, B) = \sum_{u \in B} \mathbf{T}(s, u)$

El sistema de ecuaciones puede ser reescrito como el sistema lineal

$$(\mathbf{I} - \mathbf{A}) \cdot \mathbf{x} = \mathbf{b},$$

donde  $\mathbf{I}$  es la matriz de identidad  $|\tilde{S}| \times |\tilde{S}|$ .

## Probabilidades de alcanzabilidad IV

Volvamos entonces a nuestro ejemplo de protocolo simple de comunicación y al análisis de las probabilidades de  $\diamond B$  con  $B = \{\textit{delivered}\}$ .

$x_s > 0$  para todo estado  $s$ , dado que *delivered* es alcanzable desde todos los estados, con lo que  $\tilde{S} = \{\textit{start}, \textit{try}, \textit{lost}\}$  y obtenemos las siguientes ecuaciones

$$\begin{aligned}x_{\textit{start}} &= x_{\textit{try}} \\x_{\textit{try}} &= \frac{1}{10} \cdot x_{\textit{lost}} + \frac{9}{10} \\x_{\textit{lost}} &= x_{\textit{try}}.\end{aligned}$$

Estas ecuaciones pueden ser reescritas como

$$\begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -\frac{1}{10} \\ 0 & -1 & 1 \end{pmatrix} \cdot \mathbf{x} = \begin{pmatrix} 0 \\ \frac{9}{10} \\ 0 \end{pmatrix}$$

que resulta en una única solución  $x_{\textit{start}} = x_{\textit{try}} = x_{\textit{lost}} = 1$ .

## Probabilidades de alcanzabilidad V

La técnica descripta se puede entender como un algoritmo de dos partes:

- 1 realizamos un análisis del grafo para computar el conjunto de estados que pueden alcanzar  $B$  (con un backward DFS- o un BFS)
- 2 generamos la matriz  $\mathbf{A}$  y el vector  $\mathbf{b}$  y resolvemos el sistema de ecuaciones lineales  $(\mathbf{I} - \mathbf{A}) \cdot \mathbf{x} = \mathbf{b}$

Sin embargo, si  $\mathbf{I} - \mathbf{A}$  no tiene inversa,  $(\mathbf{I} - \mathbf{A}) \cdot \mathbf{x} = \mathbf{b}$  puede tener más de una solución.

Este problema se aborda caracterizando al vector deseado como la menor solución en  $[0, 1]^{\tilde{S}}$ . Esta caracterización posibilita computar el vector de probabilidad con un método de aproximación iterativa.

Vamos a presentar un algoritmo formal pero lo haremos para un tipo de problema más general el de **alcanzabilidad restringida** o de “propiedades until”.

## Probabilidades de alcanzabilidad VI - until operator

- El evento de alcanzar  $B$  a través de un fragmento de camino que termina en un estado  $s \in B$ , y antes solo visita estados en el conjunto  $C$  usando notación LTL, se denota  $CUB$ .
- El evento  $\Diamond B$  coincide con  $SUB$
- Para  $n \geq 0$ , el evento  $CU^n B$  tiene el mismo significado que  $CUB$  excepto que se requiere alcanzar  $B$  en cuanto mucho  $n$  pasos. Formalmente,  $CU^n B$  es la unión de los cilindros básicos producidos por los fragmentos de caminos  $s_0 s_1 \dots s_k$  tales que  $k \leq n$  y  $s_i \in C$  para todo  $0 \leq i < k$  y  $s_k \in B$ .

## Probabilidades de alcanzabilidad VII

Sean  $S_{=0}$ ,  $S_{=1}$  y  $S_{\neq}$  una partición de  $S$  tal que

- $B \subseteq S_{=1} \subseteq \{s \in S \mid \Pr(s \models CUB) = 1\}$ ,
- $S \setminus (C \cup B) \subseteq S_{=0} \subseteq \{s \in S \mid \Pr(s \models CUB) = 0\}$ , y
- $S_{\neq} = S \setminus (S_{=1} \cup S_{=0})$ .

Y sean

- $\mathbf{A} = (\mathbf{T}(s, t))_{s, t \in S_{\neq}}$
- $\mathbf{b} = (b_s)_{s \in S_{\neq}}$  donde  $b_s = \mathbf{T}(s, S_{=1})$

Ahora presentaremos una caracterización de menor punto fijo para calcular el vector de probabilidad  $(\Pr(s \models CUB))_{s \in S_{\neq}}$ .

Para calcular el menor punto fijo el conjunto  $[0, 1]^{S_{\neq}}$  viene equipado con un orden parcial  $\leq$  dado por  $\mathbf{y} \leq \mathbf{y}'$  sii  $y_s \leq y'_s$  para todo  $s \in S_{\neq}$ , donde  $\mathbf{y} = (y_s)_{s \in S_{\neq}}$  e  $\mathbf{y}' = (y'_s)_{s \in S_{\neq}}$ .



## Probabilidades de alcanzabilidad VIII - punto fijo

### Teorema (Caracterización por menor punto fijo)

El vector  $\mathbf{x} = (\Pr(s \models CUB))_{s \in S_?}$  es el menor punto fijo del operador  $\Upsilon : [0, 1]^{S_?} \rightarrow [0, 1]^{S_?}$  que está dado por

$$\Upsilon(\mathbf{y}) = \mathbf{A} \cdot \mathbf{y} + \mathbf{b}.$$

Además, si  $\mathbf{x}^{(0)} = \mathbf{0}$  es el vector nulo, y  $\mathbf{x}^{(n+1)} = \Upsilon(\mathbf{x}^{(n)})$  para  $n \geq 0$ , entonces:

- $\mathbf{x}^{(n)} = (x_s^{(n)})_{s \in S_?}$ , donde  $x_s^{(n)} = \Pr(s \models CU^{\leq n} S_{=1})$  para cada estado  $s \in S_?$
- $\mathbf{x}^{(0)} \leq \mathbf{x}^{(1)} \leq \mathbf{x}^{(2)} \leq \dots \leq \mathbf{x}$ , y
- $\mathbf{x} = \lim_{n \rightarrow \infty} \mathbf{x}^{(n)}.$

La prueba de este teorema la podemos charlar pero está en la página 762

## Sobre el algoritmo que se deriva del punto fijo


- Lo obtendremos calculando iterativamente los  $\mathbf{x}^{(n+1)}$  y frenando cuando  $\max_{s \in S} |x_s^{(n+1)} - x_s^{(n)}| < \varepsilon$  para alguna tolerancia  $\varepsilon$ .
- También lo podemos usar para calcular problemas de alcanzabilidad con pasos limitados.
- Aunque la convergencia de este método está asegurada, generalmente es menos eficiente que otros métodos iterativos para resolver sistemas de ecuaciones como Jacobi o Gauss-Seidel (si han cursado métodos, en otro momento podemos charlar de qué hay que tener en cuenta al usar esos métodos para la convergencia).
- Claramente, la elección de conjuntos  $S_{=0}$  y  $S_{=1}$  más grandes genera una ejecución más eficiente y los conjuntos cota superior con los que los describimos pueden ser calculados por algoritmos de análisis de grafos que son lineales en el tamaño de la cadena de Markov.

## Un ejemplo más complejo - el juego de Craps

El juego de Craps es un juego de un jugador en el que se tiran 2 dados. La primer tirada, llamada “*come-out roll*”, determina si se necesitará otra tirada. Si la primer tirada resulta en un 7 o un 11, el juego termina y el jugador gana, si resulta en un 2, 3 o 12, estos son “*craps*”, el juego termina y el jugador pierde, mientras que si sale cualquier otro número el dado se tira otra vez pero el primer resultado es recordado como “el punto”. Si la próxima tirada es un 7 o el punto, el juego termina. Si salió el jugador pierde, si salió el punto, gana. En cualquier otro caso, se vuelve a tirar el dado hasta que salga 7 o el punto.

Intentemos armar una cadena de Markov a partir de esta descripción.

## Cadena de Markov del juego de Craps



## Alcanzabilidad restringida en el juego de Craps

Nos interesará saber la probabilidad de  $CU^{\leq n}B$  donde  $B = \{won\}$  y  $C = \{start, 4, 5, 6\}$ . Con lo que podríamos tener:

$$S_{=0} = \{8, 9, 10, lost\}, S_{=1} = \{won\}, \text{ y } S_{?} = \{start, 4, 5, 6\}$$

Usando el orden de estados  $start < 4 < 5 < 6$ , la matriz  $\mathbf{A}$  y el vector  $\mathbf{b}$  están dados por

$$\mathbf{A} = \frac{1}{36} \begin{pmatrix} 0 & 3 & 4 & 5 \\ 0 & 27 & 0 & 0 \\ 0 & 0 & 26 & 0 \\ 0 & 0 & 0 & 25 \end{pmatrix} \quad \mathbf{b} = \frac{1}{36} \begin{pmatrix} 8 \\ 3 \\ 4 \\ 5 \end{pmatrix}.$$

## Alcanzabilidad restringida en el juego de Craps - cont.

La caracterización nos propone seguir el siguiente esquema iterativo:

$$\mathbf{x}^{(0)} = \mathbf{0} \text{ y } \mathbf{x}^{(i+1)} = \mathbf{A}\mathbf{x}^{(i)} + \mathbf{b} \text{ para } 0 \leq i < n,$$

donde  $\mathbf{x}^i$  guarda para todo estado  $s \in S$  la probabilidad del evento  $CU^{\leq n}B$ . Aplicando este esquema iterativo tenemos que  $\mathbf{x}^{(1)} = \mathbf{b}$  y

$$\mathbf{x}^{(2)} = \frac{1}{36} \begin{pmatrix} 0 & 3 & 4 & 5 \\ 0 & 27 & 0 & 0 \\ 0 & 0 & 26 & 0 \\ 0 & 0 & 0 & 25 \end{pmatrix} \cdot \frac{1}{36} \begin{pmatrix} 8 \\ 3 \\ 4 \\ 5 \end{pmatrix} + \frac{1}{36} \begin{pmatrix} 8 \\ 3 \\ 4 \\ 5 \end{pmatrix} = \left(\frac{1}{36}\right)^2 \begin{pmatrix} 338 \\ 189 \\ 248 \\ 305 \end{pmatrix}$$

Luego, por ejemplo  $\Pr(\text{start} \models CU^{\leq 2}B) = \frac{338}{36}$ . De la misma manera se pueden calcular  $\mathbf{x}^{(3)}$ ,  $\mathbf{x}^{(4)}$ , etc.

## Clasificación de estados

A partir de los cálculos que vimos, existe una manera de clasificar a los estados.

- Un estado  $s$  se dice **transitorio** si hay una probabilidad positiva de abandonarlo para siempre. Es decir, si  $1 - \Pr(s \models \Diamond s) > 0$ .
- Un estado  $s$  es **recurrente** si resulta casi seguro que se vuelve a él. Es decir, si  $\Pr(s \models \Diamond s) = 1$ .

Por otro lado, diremos también que:

- un estado  $s$  es **absorbente** si  $\mathbf{T}(s, s) = 1$  y  $\mathbf{T}(s, s') = 0$  para todo  $s' \neq s$ .
- un estado  $s'$  es **accesible desde**  $s$  si  $\Pr(s \models \Diamond s') > 0$ .
- dos estados  $s$  y  $s'$  están **comunicados** si  $s'$  es accesible desde  $s$  y viceversa.

## Clasificación de estados - cont.

A su vez, un **estado recurrente**  $s$  se dice de **período**  $\delta$  cuando:

$$\delta = \text{mcd}\{n \geq 1 \mid \Pr(s \models \Diamond^n s) > 0\} \text{ y } \delta \geq 2$$

Si  $\delta = 1$  el estado  $s$  se dice **aperiódico**.

Pero, ¿cómo calculamos  $\Pr(s \models \Diamond^n s)$ ? O, en general, ¿cómo calculamos alcanzabilidad en exactamente  $n$  pasos?



## ¿Cómo calculamos alcanzabilidad en exactamente $n$ pasos?

La potencia enésima de la matriz  $\mathbf{A}$ , i.e., la matriz  $\mathbf{A}^n$  contiene las probabilidades de llegar a los estados exactamente después de  $n$  pasos, pues, la entrada de la matriz  $\mathbf{A}^n(s, t)$  es igual a la suma de las probabilidades  $\mathbf{T}(s_0 s_1 \dots s_n)$  de todos los fragmentos de caminos  $s_0 s_1 \dots s_n$  con  $s_0 = s$ ,  $s_n = t$  y  $s_i \in S_?$  para  $0 \leq i \leq n$ . Esto es:

$$\mathbf{A}^n(s, t) = \Pr(s \models S_? \mathcal{U}^n t)$$

Ahora bien, si  $B = \emptyset$  y  $C = S$ , entonces  $S_{=1} = S_{=0} = \emptyset$ ,  $S_? = S$  y  $\mathbf{A} = \mathbf{T}$ . La entrada  $\mathbf{T}^n(s, t)$  (del la potencia enésima de  $\mathbf{T}$ ) entonces es igual a la probabilidad de estar en el estado  $t$  luego de  $n$  pasos si empezamos desde el estado  $s$ , i.e.,

$$\mathbf{T}^n(s, t) = \Pr(s \models S \mathcal{U}^n t).$$

## Pero, ¿cómo calculamos alcanzabilidad en exactamente $n$ pasos?

La probabilidad de que la cadena de Markov  $\mathcal{M}$  esté en el estado  $t$  después de exactamente  $n$  pasos

$$\Theta_n^{\mathcal{M}}(t) = \iota_{init}(s) \cdot \sum_{s \in S} \mathbf{T}^n(s, t)$$

en la literatura se suele llamar *transient state probability* para el estado  $t$  y a la función  $\Theta_n^{\mathcal{M}}$  se la suele llamar la *transient state distribution*.

Estos nombres podrían resultar confusos con la clasificación de estados transitorios, entonces nosotros los llamaremos probabilidad de alcanzabilidad exacta y distribución de alcanzabilidad exacta.

Al considerar  $\Theta_n^{\mathcal{M}}$  como un vector, la ecuación de arriba se puede reescribir como:

$$\Theta_n^{\mathcal{M}} = \iota_{init} \cdot \mathbf{T}^n$$

## Ejemplo de cálculo de alcanzabilidad exacta

Volviendo a nuestro ejemplo del protocolo simple de comunicación, ahora queremos saber cuál es la probabilidad de que el mensaje sea enviado en exactamente 4 pasos, es decir, querremos saber cuánto es  $\Pr(start \models \diamond^{=4} B)$  cuando  $B = \{delivered\}$ . Tendremos que

$$\Pr(start \models \diamond^{=4} B) = \Theta_4^{\mathcal{M}}(delivered)$$

$$\Theta_4^{\mathcal{M}} = \iota_{init} \cdot \mathbf{T}^4$$

$$\Theta_4^{\mathcal{M}} = \begin{pmatrix} 1 & 0 & 0 & 0 \end{pmatrix} \cdot \begin{pmatrix} 0 & \frac{9}{10} & \frac{1}{100} & \frac{9}{100} \\ \frac{9}{100} & \frac{1}{100} & \frac{1}{100} & \frac{9}{81} \\ 0 & \frac{1}{10} & \frac{1}{100} & \frac{1}{100} \\ \frac{9}{10} & \frac{1}{10} & 0 & 0 \end{pmatrix}$$

$$\Theta_4^{\mathcal{M}}(delivered) = \frac{9}{100}$$

## Clasificación de estados II – Irreducibilidad y periodicidad global

- Una cadena de Markov es **irreducible** si todos los pares de estados están comunicados entre sí.

$$\forall s, t \in S, \Pr(s \models \Diamond t) > 0 \text{ y } \Pr(t \models \Diamond s) > 0$$

- La cadena es **aperiódica** si todos sus estados tienen período igual a 1:

$$\forall s \in S, \text{mcd}\{n \geq 1 \mid \Pr(s \models \Diamond^n s) > 0\} = 1$$

## ¿Por qué irreducibilidad y aperiodicidad? - Distribución estacionaria

- **Irreducibilidad** asegura que es posible llegar a cualquier estado desde cualquier otro. Esto garantiza que la cadena no tenga múltiples “bloques aislados” con comportamientos distintos.
- **Aperiodicidad** evita que la cadena oscile de forma rígida entre estados. Esto es crucial para que la distribución converja a una única distribución límite.
- Estas condiciones serán condiciones suficientes para existencia, unicidad y convergencia hacia una **distribución estacionaria** o invariante de probabilidades de transición de una cadena de Markov.

## Distribución estacionaria

- Una **distribución estacionaria** de una cadena de Markov con matriz de transición  $T$  es un vector de probabilidad  $\pi$  tal que:

$$\pi T = \pi \quad \text{y} \quad \sum_{s \in S} \pi(s) = 1$$

- Si la cadena comienza con distribución  $\pi$ , entonces su distribución se mantiene constante para todos los tiempos.
- Cuando existe, describe el **comportamiento a largo plazo** de la cadena.
- Para obtenerla se puede:
  - Resolver el sistema lineal  $\pi T = \pi$  junto con  $\sum \pi_i = 1$ .
  - Tomar  $\pi = \lim_{n \rightarrow \infty} \nu_{init} T^n$  si la cadena cumple las condiciones de irreducibilidad y aperiodicidad.

## Ejemplo: cálculo de distribución estacionaria

Consideremos la siguiente matriz de transición:

$$T = \begin{pmatrix} 0,7 & 0,3 \\ 0,4 & 0,6 \end{pmatrix}$$

Queremos hallar  $\pi = (\pi_1, \pi_2)$  tal que:

$$\pi T = \pi \quad \text{y} \quad \pi_1 + \pi_2 = 1$$

Esto da el sistema:

$$\begin{cases} 0,7\pi_1 + 0,4\pi_2 = \pi_1 \\ 0,3\pi_1 + 0,6\pi_2 = \pi_2 \\ \pi_1 + \pi_2 = 1 \end{cases} \Rightarrow \pi = \left( \frac{4}{7}, \frac{3}{7} \right)$$

## Ejemplo: cálculo de distribución estacionaria

Si con R o algún otro software estadístico calculamos  $T^n$  para algún  $n$  lo suficientemente grande podemos calcular una aproximación de  $\pi$ . Veamos esto calculando  $T^{50}$  en R:

$$T^{50} = \begin{pmatrix} 0,5714286 & 0,4285714 \\ 0,5714286 & 0,4285714 \end{pmatrix}$$

Como  $\frac{4}{7} \approx 0,5714286$  y  $\frac{3}{7} \approx 0,4285714$ , podemos ver que la cadena converge hacia  $\pi$  con cualquier distribución inicial.



## ¿Qué vimos que podemos hacer con cadenas de Markov?

- ver la probabilidad de llegar a un estado en un conjunto  $B$ .
- ver la probabilidad de llegar a un estado en un conjunto  $B$  solo pasando antes por estados en un conjunto  $C$ .
- ver la probabilidad de llegar a un estado en un conjunto  $B$  en  $n$  o menos pasos.
- ver la probabilidad de llegar a un estado en un conjunto  $B$  en exactamente  $n$  pasos.
- ver el comportamiento a largo plazo de una cadena.